Guía personal — Hito 3 RompeBrechas

Secciones 10–14: clustering, mapas y clustering espacial

Contexto rápido

Cada fila es un colegio de primaria (37,260 con datos completos). El objetivo es encontrar **perfiles de colegios** según su contexto y su capacidad institucional para gestionar la convivencia, y luego ver **dónde** están. Los 9 atributos que entran a la distancia son:

- **Contexto:** `log_mat_total` (matrícula en log), `urbano`, `gestion_privada`.
- **Instrumentos (sí/no):** `resp_convivencia`, `afiliado_siseve`, `conoce_protocolos`, `reporta_ugel`, `consulta_rnssc`, `actividad_esi`.

No entran (solo sirven para interpretar): el resultado (`registra_incidencia`, tasas de incidencias), `tiene_libro` (sería circular: es el instrumento con el que se registra) y repetición/retiro. Esto es clave: si después un grupo "tiene menos libro", es un hallazgo, no algo que el modelo forzó.

10 Clustering con K-means

10.1 Escalas y outliers (10.1–10.3)

```
X_km = datos_km[atributos_km].astype(float)
X_km.melt(...) # formato largo para el boxplot
sns.catplot(data=X_km_long, x="atributo", y="valor", kind="box")
X_std_km = StandardScaler().fit_transform(X_km)
```

Se arma la matriz (0 faltantes), se dibuja un boxplot por variable en unidades originales y luego se estandariza con z-score.

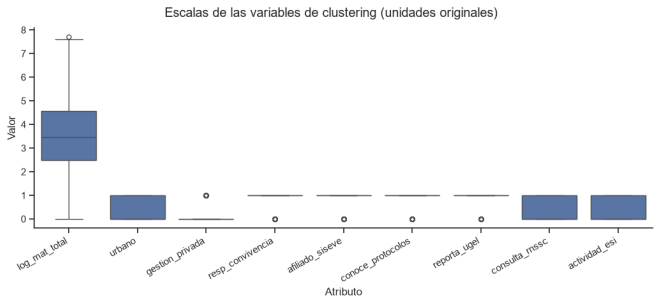


Figura 1: Boxplots de las 9 variables antes de escalar.

Lectura: La matrícula (log) va de 0 a 7.7; las otras 8 van de 0 a 1. Sin escalar, la matrícula dominaría la distancia euclidiana solo por su rango. Las binarias se ven como "cajas planas": en `resp_convivencia`, `afiliado_siseve`, `conoce_protocolos` y `reporta_ugel` casi todos valen 1 y los 0 aparecen como "outliers" (puntos), pero no son errores, solo la categoría rara. En `urbano`, `consulta_rnssc` y `actividad_esi` la caja ocupa 0–1 porque están más repartidas (33 %, 44 %, 44 % de unos).

Tras el `StandardScaler` todo queda con media 0 y desviación 1. Detalle importante: en una binaria desbalanceada el "no" raro queda muy lejos (p. ej. sin responsable de convivencia → $z \approx -2.6$, con responsable → $+0.38$). O sea, **no tener un instrumento pesa más que tenerlo** en la distancia. Es intencional: es justo lo que interesa detectar.

10.2 Elegir K: codo, silueta, Davies-Bouldin (10.4–10.6)

```
for k in range(2, 7):
    km = KMeans(n_clusters=k, init="k-means++",
                n_init=10, random_state=42).fit(X_std_km)
    silhouette_score(X_std_km, km.labels_, sample_size=10_000)
    davies_bouldin_score(X_std_km, km.labels_)
```

Se entrena K-means para cada K y se guardan tres métricas.

- **Inercia**: suma de distancias al cuadrado de cada colegio a su centroide. Siempre baja al subir K; se busca el "codo".
- **Silueta** (-1 a 1): ¿está cada colegio más cerca de su grupo que del vecino? Mayor es mejor. Se calcula en una muestra de 10 mil por costo ($O(n^2)$).
- **Davies-Bouldin**: razón dispersión interna / separación entre grupos. Menor es mejor.

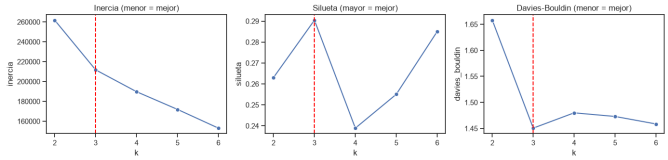


Figura 2: Inercia, silueta y Davies-Bouldin para K = 2. . . 6; la línea roja marca K = 3.

Lectura: (Fig. 2) La inercia cae fuerte de 2 a 3 (261.8k → 211.8k) y después más suave: codo en K = 3. La silueta tiene su pico en K = 3 (0.290) y un segundo pico casi igual en K = 6 (0.285); K = 4 es el peor (0.239). Davies-Bouldin tiene su mínimo en K = 3 (1.451). Las tres métricas apuntan a K = 3. Pero ojo: una silueta de 0.29 es **débil**: los grupos se tocan en los bordes, hay colegios "intermedios".

Estabilidad. Como K = 3 y K = 6 tienen silueta casi igual, se repite la silueta con 5 muestras distintas y se compara K-means con 4 semillas distintas usando el **ARI** (Adjusted Rand Index: 1 = mismas agrupaciones, 0 = coincidencia al azar).

K	Silueta (rango)	ARI mín	ARI máx
2	0.261–0.267	1.000	1.000
3	**0.288–0.295**	**1.000**	**1.000**
4	0.238–0.245	0.946	1.000
5	0.254–0.262	0.401	0.779
6	0.283–0.292	0.447	0.982

Tabla 1: Estabilidad por K.

Lectura: Por silueta K = 3 y K = 6 se traslapan (no se distinguen). Lo que decide es la estabilidad: K = 3 da exactamente los mismos grupos con cualquier semilla (ARI = 1), K = 6 y K = 5 cambian bastante. Se elige **K = 3**: la opción más estable entre las de mejor métrica y la más simple de explicar a la UGEL.

10.3 Modelo final y perfiles (10.7–10.8)

```
kmeans = KMeans(n_clusters=3, init="k-means++", n_init=10,
     random_state=42)
datos_km["cluster_kmeans"] = kmeans.fit_predict(X_std_km)
# nombrar por perfil, no por el número arbitrario
c_pocos = perfil["resp_convivencia"].idxmin()
c_urbano = perfil.drop(c_pocos)["mat_total"].idxmax()
```

```
perfil_z = (perfil - X_km.mean()) / X_km.std(ddof=0)
sns.heatmap(perfil_z, annot=True, center=0, cmap="vlag")
```

Los números 0/1/2 de K-means son arbitrarios, así que el código nombra cada grupo por su perfil (el de menos responsables = "Pocos instrumentos"; de los otros dos, el de mayor matrícula = "Urbano grande"). Así los nombres no se rompen si cambia la semilla. Tamaños: **Pocos instrumentos** 5,075; **Rural con instrumentos** 20,725; **Urbano grande** 11,460.

Lectura: (Fig. 3) Cada celda = (promedio del grupo − promedio global)/desv. global. Rojo = por encima del promedio, azul = por debajo.

- **Pocos instrumentos**: azul intenso en los 4 instrumentos centrales (−1.4 a −1.65). En unidades originales: solo 37 % tiene responsable, 25 % afiliado al SíseVe, 32 % conoce protocolos, 45 % sabe reportar a la UGEL (vs. ≈90–95 % en los otros). Contexto casi neutro: pequeño y mayormente rural (16 % urbano).
- **Rural con instrumentos**: urbano −0.70 (0 % urbano), privado −0.52 (0 % privado), instrumentos ligeramente positivos. Público, rural, pequeño, *pero equipado*.
- **Urbano grande**: rojo en contexto (100 % urbano, 61 % privado, matrícula media 237 vs. ≈35). Instrumentos parecidos al rural; destaca en consulta RNSSC (+0.40).

Lo interesante: el eje que separa a *Pocos instrumentos* no es el contexto sino la **falta de instrumentos**. ESI con familias casi no discrimina (0.08 en dos grupos).

Variables de interpretación (no entraron al modelo): `tiene_libro` = 41 % en Pocos instrumentos vs. 88 % y 93 % en los otros. Es decir, **el 59 % de Pocos instrumentos no tiene libro**, aunque el libro nunca entró a la distancia: el grupo "descubrió" a los colegios sin libro. Por departamento (tabla cruzada) el grupo pesa más en Loreto (43 %), Ucayali (32 %), Madre de Dios (29 %); Urbano grande domina Callao (88 %) y Lima (83 %).

¿Registran distinto? Como los colegios grandes registran más, se compara el % que registra al menos una incidencia *a igual tamaño*:

Grupo	≤20	21–50	51–100	>100
Pocos instr.	3.1	7.9	7.0	13.0
Rural c/ instr.	4.9	9.0	15.0	22.8
Urbano grande	3.4	7.1	11.4	33.3

Tabla 2: % que registra incidencias por tamaño de matrícula.

Lectura: Globalmente: Urbano grande 24.5 %, Rural 8.8 %, Pocos 5.5 %. Pero el 24.5 % urbano es casi todo efecto tamaño: solo supera al rural en colegios de más de 100 estudiantes. La comparación justa es Pocos vs. Rural (tamaños parecidos): Pocos registra menos *en los cuatro tramos*. No se sabe si es por menos capacidad o menos violencia (es asociación). Además, Pocos solo tiene 2,265 de 5,075 colegios con dato (los sin libro no tienen dato), y algunas celdas son chicas (154).

10.4 Comparación con DBSCAN (10.9)

```
min_vecinos = 2 * X_std_km.shape[1] # 18
dist, _ = NearestNeighbors(n_neighbors=18).fit(X).kneighbors(X)
plt.plot(np.sort(dist[:, -1])) # gráfico de k-distancias
DBSCAN(eps=2.7, min_samples=18).fit_predict(X_std_km)
```

DBSCAN no pide K, pide `eps` (radio) y `min_samples` (vecinos mínimos). El gráfico de k-distancias ayuda a elegir `eps`.

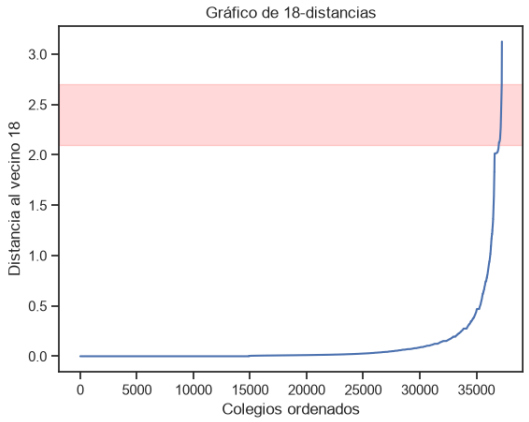


Figura 4: Distancia de cada colegio a su vecino 18, ordenada. Franja roja: rango de `eps` probado.

Lectura: (Fig. 4) La curva es **plana en cero para ∼15 mil colegios**: cada uno tiene al menos 18 colegios con *exactamente* las mismas respuestas (8 de 9 variables son sí/no, hay pocas combinaciones posibles). Recién al final sube en escalones hasta ∼3. Consecuencia: el resultado es hipersensible a `eps` (con `min_samples`=18: 39 grupos con 2.1, 16 con 2.5, 8 con 2.7, 2 con 3.0), mientras `min_samples` (9, 18, 36) casi no cambia nada. Se usa `eps`=2.7 (8 grupos).

Resultado DBSCAN: un grupo gigante (75 %, 27,954 colegios) con los tres instrumentos (responsable, protocolos, reporta UGEL) y 7 grupos que son *cada combinación de qué instrumento falta*. 0 % ruido. El **grupo 5** (sin ninguno de los tres; 1,112 colegios) es el más crítico: solo 15 % tiene libro. DBSCAN no separa por contexto (urbano/privado/tamaño), solo por "qué falta", porque los "no" raros pesan más tras el z-score.

10.5 Comparación con jerárquico (10.10)

```
muestra = rng.choice(len(X_std_km), size=10_000, replace=False)
Z_ward = linkage(X_std_km[muestra], method="ward")
dendrogram(Z_ward, truncate_mode="lastp", p=30)
fcluster(Z_ward, t=3, criterion="maxclust")
NearestCentroid().fit(X_muestra, etiquetas).predict(X_std_km)
```

Con 37 mil colegios la matriz de distancias tendría ∼700 millones de pares: no cabe en memoria. Se arma el árbol con 10 mil y luego se asigna el resto al centroide más cercano.

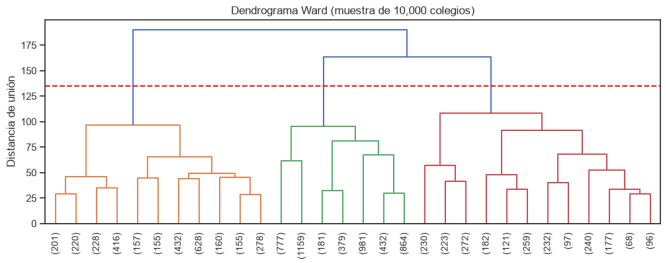


Figura 5: Dendrograma Ward (últimas 30 ramas). Entre paréntesis: colegios por rama. Línea roja: corte en 3 grupos.

Lectura: (Fig. 5) El eje vertical es la "distancia de unión" (cuánto aumenta la varianza interna al juntar dos ramas). El salto vertical más largo está entre ∼110 y ∼165: cortar ahí (línea roja) da **3 ramas** (naranja, verde, roja), coherente con el codo. La rama roja se une recién a ∼110 y la unión final a ∼190, mostrando que hay tres bloques bien diferenciados en la muestra.

Tipos de enlace con 3 grupos: **ward** (silueta 0.270, ARI con K-means 0.759, tamaños razonables); **average** tiene

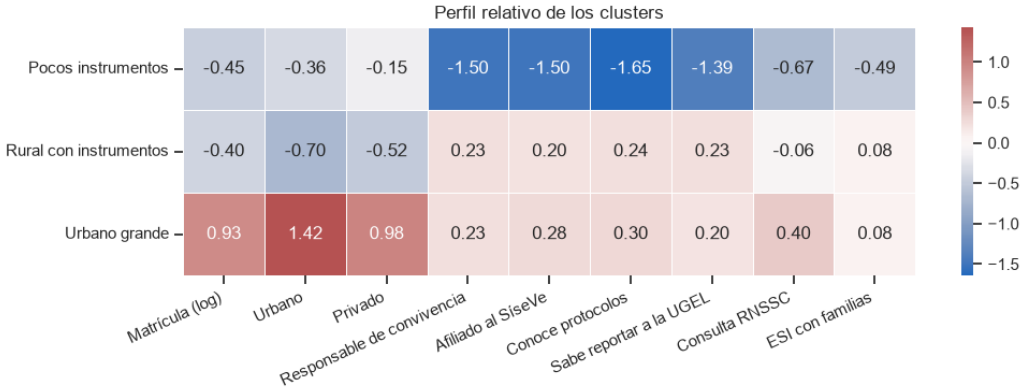


Figura 3: Heatmap del perfil relativo: promedio de cada grupo expresado en desviaciones estándar respecto del promedio nacional.

la mejor silueta (0.312) pero deja grupos [9144, 855, **1**]: *una métrica sola engaña*. Se usa Ward. Coincidencia con K-means: 90 % (árbol sin asignar, ARI 0.759) y 94.5 % asignando por centroides (ARI 0.856, inflado porque ese paso imita a K-means). Diferencia principal: pasa 1,890 colegios de Rural a Pocos instrumentos.

10.6 Otras representaciones y resumen (10.11–10.12)

Representación	Silueta	DB	ARI
9 atributos z-score (elegida)	0.290	1.451	1.000
6 componentes PCA	0.323	1.291	0.995
9 atributos sin escalar	0.257	1.336	0.263

Tabla 3: K-means K = 3 sobre distintas representaciones.

Lectura: PCA da casi los mismos grupos (ARI 0.995) ⇒ no hace falta; se prefieren los 9 atributos porque se leen directo. **Sin escalar** todo cambia (ARI 0.263): los grupos se separan solo por tamaño (log-matrícula 1.83 / 3.53 / 5.33) y casi no por instrumentos. Las siluetas no se comparan entre representaciones (espacios distintos); por eso se usa ARI.

Resumen de métodos: K-means (3 grupos, silueta 0.290, DB 1.451), DBSCAN (8 grupos, 75 % en uno, silueta 0.291, ARI 0.262), Jerárquico Ward (3 grupos, silueta 0.281, ARI 0.856). Ninguno separa mucho mejor; K-means queda como principal por su DB y tamaños útiles.

11 Datos geoespaciales

```
regiones = gpd.read_file("peru_shapes/per_admbnda_adm1_ign_20200714
      .shp")
geo["ADM1_PCODE"] = "PE" + geo["CODGEO_padron"].str[:2]
colegios_gdf = gpd.GeoDataFrame(geo,
    geometry=gpd.points_from_xy(geo["NLONG_IE"], geo["NLAT_IE"]),
          crs="EPSG:4326")
regiones["area_km2"] = regiones.to_crs("EPSG:32718").area / 1e6
```

Se lee el shapefile del IGN (25 departamentos, en grados WGS84 = EPSG:4326). Cada colegio pasa a ser un punto. La unión colegio–departamento se hace por **código** (`PE` + 2 primeros dígitos del ubigeo) y no por nombre, porque los nombres difieren en tildes/mayúsculas (0 colegios sin match). Para medir área hay que pasar a metros: `to_crs(.EPSG:32718")` (UTM 18S). 4,367 colegios registran incidencias y 6,269 no tienen libro.

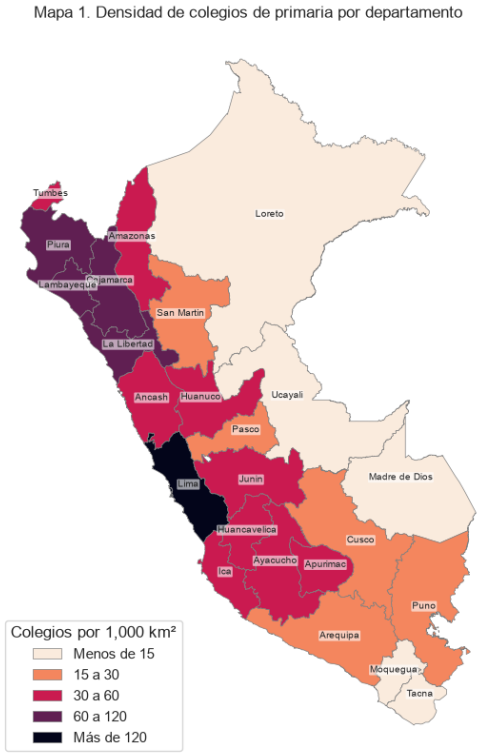


Figura 6: Mapa 1. Colegios de primaria por cada 1,000 km² (tramos).

Lectura: (Fig. 6) Coroplético con densidad agrupada en 5 tramos (con escala continua, Callao >3,500 y Lima >150 aplastarían a todos). Lima es el único en negro; costa norte (Piura, Lambayeque, La Libertad, Cajamarca) en morado oscuro. Los más claros son **Loreto (6.3), Ucayali (8.0) y Madre de Dios (2.6)**: colegios muy dispersos, lejos de su UGEL. Y coinciden con mucho % sin libro (51 %, 38 %, 26 %). Pero la densidad sola no explica: Moquegua y Tacna también son claros y casi todos tienen libro (9 %, 3 % sin libro).

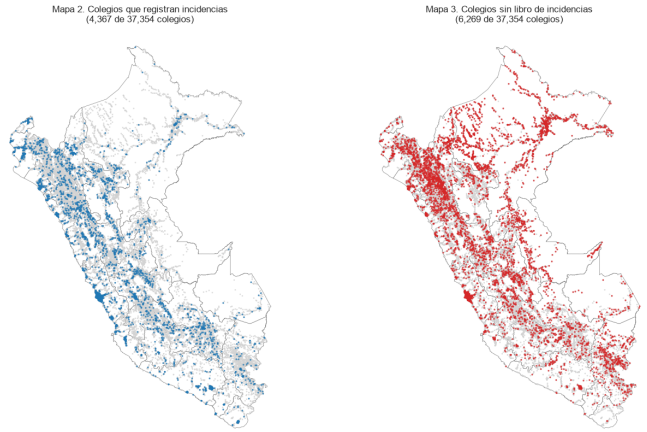


Figura 7: Mapa 2 (azul): colegios que registran incidencias. Mapa 3 (rojo): colegios sin libro. Gris: todos los colegios.

Lectura: (Fig. 7) Mapas de puntos: gris = todos, color = el subgrupo. **Azul** se concentra en la costa y ciudades (manchas en Lima, Trujillo, Arequipa, Tacna); en la selva casi no hay azul fuera de Iquitos. **Rojo** sigue las líneas de los ríos amazónicos (se ven como "hilos" en Loreto), se acumula en la sierra norte (Cajamarca) y en Puno. Son casi complementarios: donde hay rojo, falta azul. Loreto: 7.1 % registra / 50.9 % sin libro; Tacna: 22.2 % / 2.5 %. Excepción: Huancavelica registra poco (4.4 %) aunque casi todos tienen libro: ahí el bajo registro no se explica por falta de libro.

Idea central: en las zonas rojas un "cero incidencias" no significa "sin violencia": no hay dónde anotarla.

12 Clustering espacial

Dos preguntas distintas: (a) *¿qué colegios se parecen?* → clustering por atributos y después mapa; (b) *¿dónde se juntan los colegios sin libro?* → DBSCAN solo con coordenadas.

12.1 K-means visto en el mapa (12.1)

```
colegios_gdf["grupo_kmeans"] = datos_km["cluster_kmeans"].map(
      nombres_cluster)
for ax, (grupo, color) in zip(axes, colores_grupo.items()):
    colegios_gdf.plot(ax=ax, color="lightgray", markersize=0.3)
    colegios_gdf[colegios_gdf["grupo_kmeans"] == grupo].plot(ax=ax,
          color=color)
```

Lectura: (Fig. 8) Aunque K-means **no usó coordenadas**, los grupos forman regiones: **Urbano grande** (azul) = puntos en la costa y capitales; **Rural con instrumentos** (verde) cubre casi toda la sierra de forma densa; **Pocos instrumentos** (rojo) dibuja los ríos de la Amazonía y aparece en Cajamarca y Puno. Que el patrón geográfico emerja solo de las características del colegio refuerza que los grupos tienen sentido. % en Pocos instrumentos: Loreto 43, Ucayali 32, Madre de Dios 29, Pasco 25, Amazonas 24.

12.2 DBSCAN espacial de colegios sin libro (12.2)

```
sin_libro_m = colegios_gdf[colegios_gdf["sin_libro"]].to_crs("EPSG
      :32718")
coords_m = np.column_stack([sin_libro_m.geometry.x, sin_libro_m.
      geometry.y])
d, _ = NearestNeighbors(n_neighbors=30).fit(coords_m).kneighbors(
      coords_m)
sin_libro_m["zona"] = DBSCAN(eps=30_000, min_samples=30).
      fit_predict(coords_m)
```

Primero se reproyecta a metros. El notebook muestra el error típico: con grados, `eps=30_000` serían 30 mil grados ⇒ todo queda en **1 sola zona**. `min_samples`=30 porque interesa encontrar zonas con *muchos* colegios sin libro.

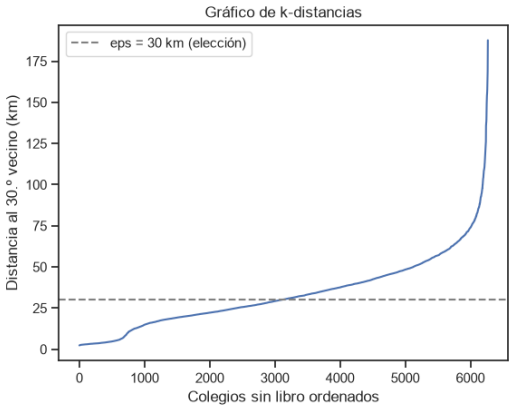


Figura 9: k-distancias: distancia al 30.º vecino sin libro (km).

Lectura: (Fig. 9) Mediana 30 km, percentil 90 = 60 km. La curva sube suave hasta ∼60–75 km y luego se dispara (hasta ∼185 km): esos son los colegios aislados. Probando `eps`: 10 km → 87 % ruido; 20 km → 22 zonas, 60 % ruido; **30 km → 22 zonas, 34 % ruido**; 40–50 km → zonas gigantes de 3–5 mil colegios. 30 km da zonas de escala "provincia", útiles para planear visitas.

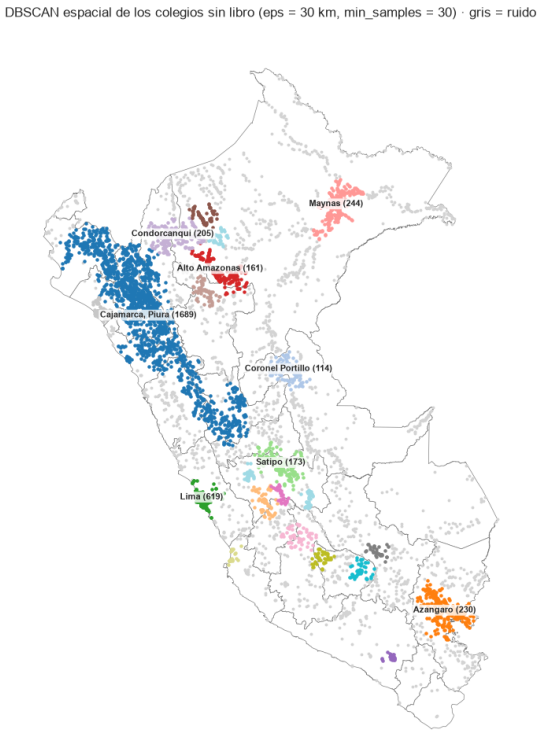


Figura 10: Las 22 zonas DBSCAN (colores) y el ruido (gris).

Lectura: (Fig. 10) La zona más grande (azul, 1,689 colegios) es una **franja continua por la sierra norte**, de Piura/Cajamarca hasta La Libertad y Huánuco: DBSCAN encuentra formas alargadas, no solo círculos. Le siguen Lima (619), Maynas/Iquitos (244), Azángaro/Puno (230), Condorcanqui (205). Ojo: Lima sale grande por *cantidad* (en la provincia solo 12 % no tiene libro), mientras Condorcanqui es chica pero con 61 % sin libro. **Limitación**: en la Amazonía el 56 % de colegios sin libro queda como ruido (vs. 26 % en el resto), porque están dispersos a lo largo de ríos. Las provincias más críticas en proporción (Datem del Marañón 85 %, Purús 82 %, Putumayo 69 %) casi no forman zonas.

12.3 Mapa de calor vs. DBSCAN (12.3)

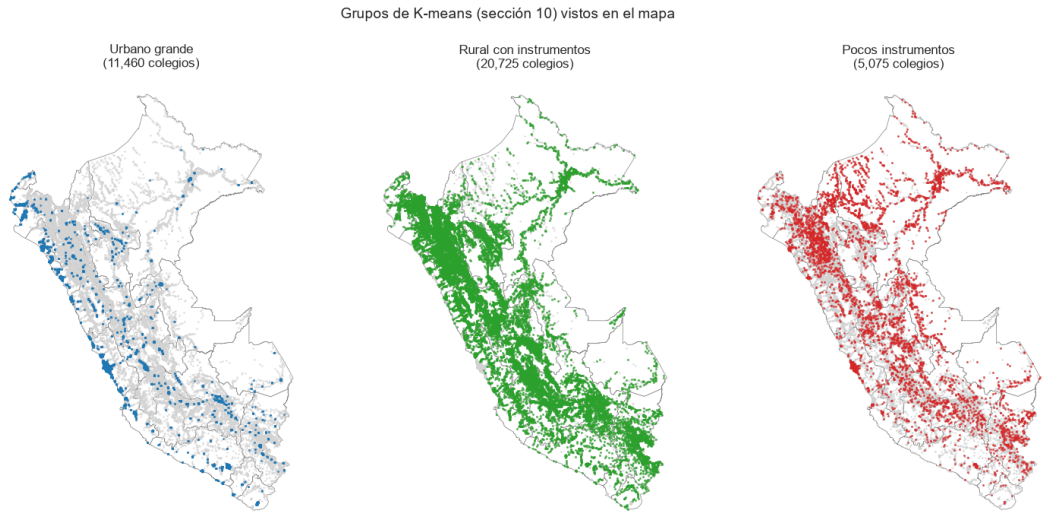


Figura 8: Los tres grupos de K-means en el mapa (la ubicación no entró al modelo).

```
sns.kdeplot(x=sin_libro_m.geometry.x, y=sin_libro_m.geometry.y,
            fill=True, cmap="rocket_r", levels=15, thresh=0.05,
                  bw_adjust=bw)
```

El KDE (estimación de densidad por kernel) suaviza los puntos en una superficie continua.

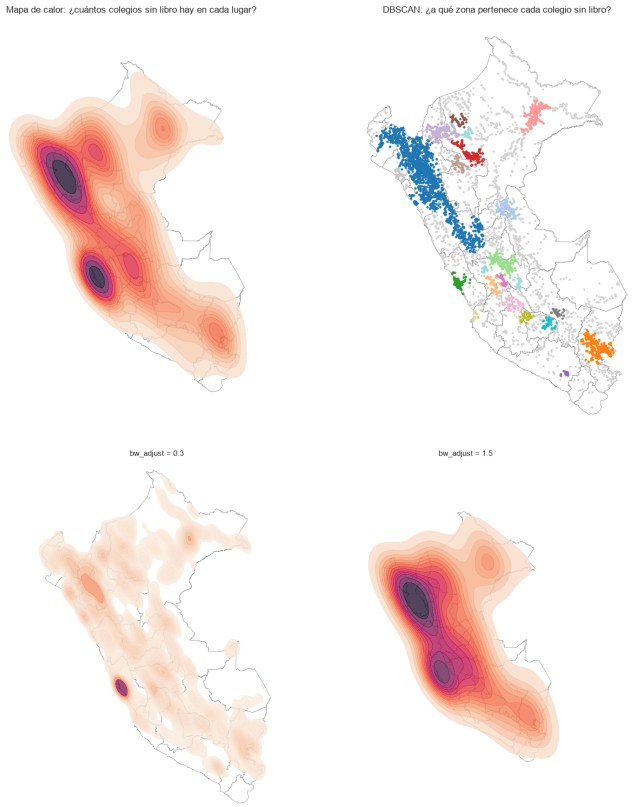


Figura 11: Arriba: mapa de calor (bw por defecto) vs. DBSCAN. Abajo: el mismo KDE con `bw_adjust` = 0.3 y 1.5.

Lectura: (Fig. 11, arriba) Ambos marcan los mismos focos: sierra norte (mancha más oscura) y Lima, y más débil Iquitos, selva central y Puno. El KDE se lee fácil, pero **pinta el mar y zonas sin colegios** y no asigna etiqueta por colegio; DBSCAN sí (sirve para listar colegios por zona). Ninguno mide *proporción*: muestran dónde hay *muchos* colegios sin libro, no dónde es *más común* (para eso está el Mapa 3). (Abajo) El ancho de banda es como el `eps`: con 0.3 salen muchos focos chicos y el más intenso es Lima (muchos colegios juntos); con 1.5 solo quedan dos manchas grandes (norte y centro) que se salen al mar y al extranjero. El patrón depende de la escala.

12.4 Desafío S12: sensibilidad (12.4)

A. K = 2 y K = 4 (mismos 9 atributos, solo cambia K; se cruza con los grupos de K = 3).

Lectura: K = 2: *Pocos instrumentos* desaparece; 4,289 de sus colegios se funden con el rural y 786 (urbanos) con el urbano. El mapa queda "ciudad vs. campo" y esconde el grupo que más interesa. **K = 4** (Fig. 12): el grupo 1 (naranja, 4,966; responsable 37 %) es *Pocos instrumentos* casi intacto y sigue los ríos amazónicos; el grupo 3 (rojo, 100 % urbano) es Urbano grande. Lo que se parte es el rural, en grupo 0 (ESI 0 %) y grupo 2 (ESI 100 %): ambos cubren toda la sierra y la selva *igual*, o sea, esa división no forma regiones. Conclusión: los perfiles útiles no dependen de K = 3 exacto, pero sí de no usar menos de 3.

B. DBSCAN con `min_samples` = 15 y 60 (`eps`=30 km fijo). Se mide además la mediana de distancia de cada colegio al centro de su zona.

ms	zonas	% ruido	% ruido Amaz.	zona mayor	km centro
15	26	11	18	3,236	154
30	**22**	**34**	**56**	**1,689**	**45**
60	10	65	84	846	26

Tabla 4: Efecto de `min_samples`.

Lectura: (Fig. 13) `min_samples` es la densidad mínima exigida. Con 15 casi todo forma zona y las zonas se *encadenan*: la azul baja de Piura hasta el centro del país (3,236 colegios, mitad a >154 km del centro: inútil para una visita). Con 60 solo sobreviven los núcleos densos (Cajamarca, Maynas, Lima…) y la Amazonía es 84 % ruido. 30 es el punto medio: el ruido amazónico se puede bajar, pero solo uniendo zonas lejanas.

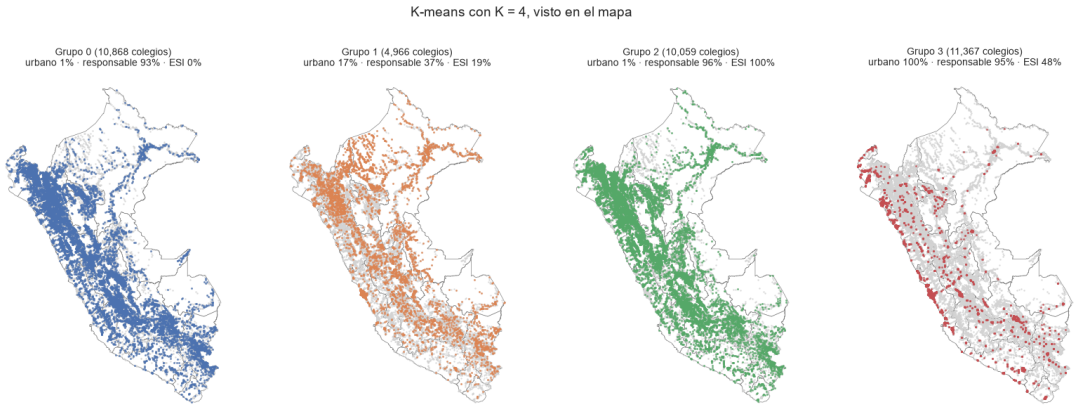


Figura 12: K-means con K = 4 en el mapa; el título de cada panel resume % urbano, % con responsable y % con ESI.

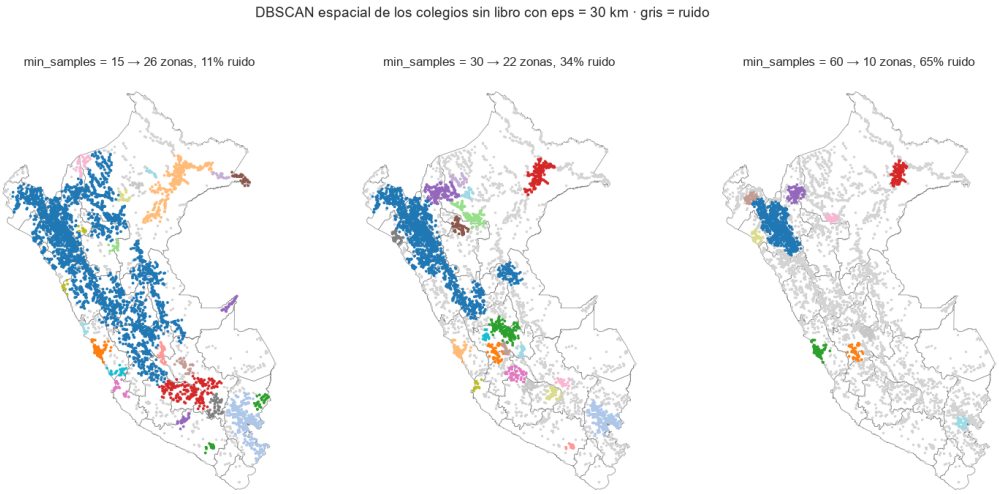


Figura 13: DBSCAN espacial con `min_samples` = 15, 30 y 60.

B adicional. K-means y jerárquico con coordenadas.

```
Z_coords = linkage(coords_m, method="ward")
corte_4 = (Z_coords[-4, 2] + Z_coords[-3, 2]) / 2 # deja 4 ramas
modelos = {"K-means (22)": KMeans(22), "Jerárquico (22)":
      AgglomerativeClustering(22, linkage="ward"),
          "DBSCAN": DBSCAN(30_000, min_samples=30), ...}
```

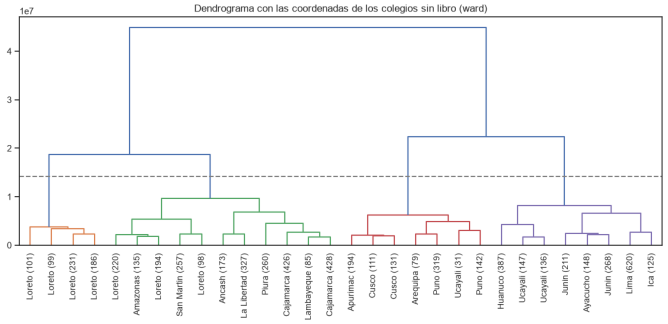


Figura 14: Dendrograma Ward con coordenadas de colegios sin libro; cada hoja indica departamento más frecuente y nº de colegios.

Lectura: (Fig. 14) El eje está en 10^7 (distancias en metros al cuadrado acumuladas). El salto más alto separa **norte** (Loreto, Amazonas, San Martín, Cajamarca, Piura, La Libertad) vs. **centro-sur**. La línea gris deja 4 ramas: Loreto (naranja), norte andino (verde), sur (rojo: Apurímac, Cusco, Arequipa, Puno) y centro (morado: Huánuco, Junín, Ayacucho, Lima, Ica). Son macrorregiones, no zonas de trabajo. No hay salto especial en 22.

Lectura: (Fig. 15) K-means y jerárquico **reparten a todos** los colegios, incluidos los aislados: cortan el país en "teselas" (sin ruido). Con 22 grupos, la mitad de colegios queda a 68–69 km del centro de su grupo vs. **45 km en DBSCAN**. Con 4 grupos son macrorregiones (>170 km). DBSCAN solo marca zonas donde de verdad hay densidad y respeta formas alargadas; su costo es el ruido amazónico. K-means(22) tendría uso si la UGEL quisiera asignar *todos* los colegios a territorios.

12.5 Decisión y mapa interactivo (12.5–12.7)

- **Principal**: clustering por atributos + mapa (responde "qué colegios tienen poca capacidad" y muestra dónde).
- **Apoyo**: DBSCAN espacial, para logística (capacitaciones en zonas densas).
- **Solo presentar**: mapa de calor. **No**: K-means/jerárquico con coordenadas.

El **mapa Folium** (`salidas/mapa_ugel_sin_libro.html`) tiene 3 capas: coroplético de % sin libro por departamento (con `.explore()`), mapa de calor (`HeatMap`, apagado al inicio) y `CircleMarker` para los **1,112 colegios sin ninguno de los 3 instrumentos** (rojo si además no tienen libro), con popup de nombre, código, matrícula y zona DBSCAN. Resultado: 351 están en Loreto (1 de cada 3), 949 (85 %) tampoco tienen libro; de esos, 630 caen en una zona DBSCAN (visita grupal) y 319 están aislados (atención uno a uno). Limitación: el color del departamento es un promedio (Loreto 51 % esconde Datem del Marañón 85 %).

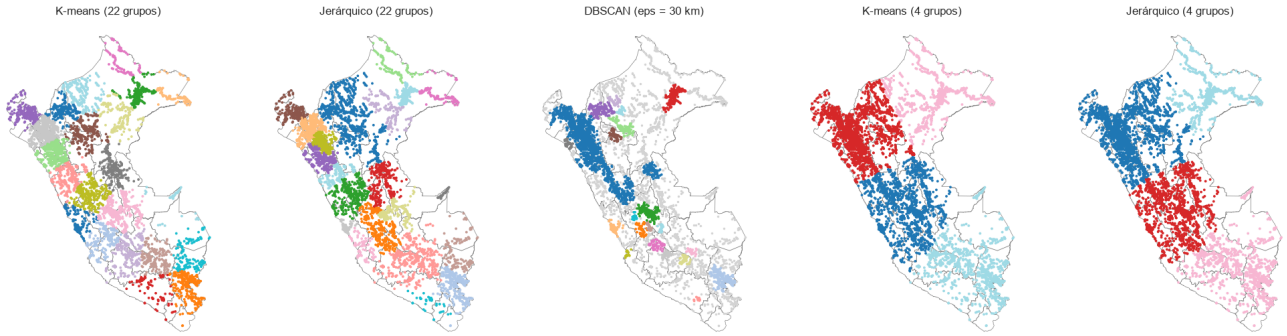


Figura 15: Mismas coordenadas, cinco algoritmos. Solo DBSCAN deja ruido (gris).

13 Problemas pendientes y hallazgos (13–14)

Problemas: binarias ⇒ colegios idénticos y DBSCAN inestable en `eps`; z-score amplifica los "no"; silueta débil (0.29) ⇒ usar grupos para priorizar, no clasificar; jerárquico solo con muestra; efecto tamaño en el registro; Amazonía dispersa ⇒ ruido en DBSCAN. **Abierto:** ¿K = 3 o más detalle? ¿distancia de Gower para binarias? **Falta (Hito 4):** reglas de asociación (Apriori) entre instrumentos, lista priorizada para la UGEL, describir perfiles con factores NMF, relación con repetición/retiro por grupo, pruebas de sensibilidad.

Hallazgos clave en una línea cada uno:

1. 71.5 % tiene libro y anotó cero; 16.8 % no tiene libro; solo 11.7 % registra.
2. Sin libro se concentra en la Amazonía (Loreto 51 %, Ucayali 38 %; Tacna 3 %).
3. Sin los 3 instrumentos ⇒ 85 % sin libro; con los 3 ⇒ 9 %.
4. K-means encuentra 3 perfiles; *Pocos instrumentos* tiene 59 % sin libro sin que el libro entre al modelo, y registra menos que el rural a igual tamaño.
5. Registrar (costa/ciudades) y no poder registrar (ríos amazónicos, sierra norte, Puno) ocupan lugares distintos del mapa.
6. DBSCAN: 22 zonas de colegios sin libro; la mayor en la sierra norte; 56 % de la Amazonía queda como ruido.
7. Limitación de fondo: se mide violencia *registrada*, no *ocurrida*; análisis transversal, sin causalidad.