Registro de violencia escolar en colegios de primaria del Perú: perfiles de capacidad institucional con clustering

Mateo Pereyra, Raúl Porras, Mauro Martínez
Curso: Data Mining
Universidad del Pacífico
Docente: Soledad Espezúa Llerena

***Resumen*—La mayoría de colegios de primaria del Perú reporta cero casos de violencia escolar, pero ese cero puede significar que no hubo violencia o que el colegio no puede registrarla. Este avance busca perfiles de colegios según su capacidad institucional, para ayudar a las UGEL a priorizar. Integramos cuatro fuentes públicas del MINEDU y aplicamos K-means sobre nueve atributos de contexto y convivencia en 37,260 colegios. Comparamos K de 2 a 6, tres representaciones y dos métodos alternativos (DBSCAN y jerárquico). K = 3 fue la opción más estable entre las de mejor métrica, aunque la separación entre grupos es débil (silueta 0.29). En el grupo con pocos instrumentos, el 59 % de los colegios no tiene libro de incidencias. Los resultados son preliminares.**

***Palabras clave*—minería de datos, clustering, K-means, violencia escolar, educación primaria**

I. Introducción

En el Perú, cada colegio debe anotar los casos de violencia escolar en un libro de incidencias y reportarlos al SíseVe, el portal del Ministerio de Educación (MINEDU) [1]. Con esa información, las Unidades de Gestión Educativa Local (UGEL) deciden a qué colegios acompañar. Pero el 71.5 % de los colegios de primaria tiene libro y anotó cero incidencias en 2024, el 16.8 % no tiene libro y solo el 11.7 % registró al menos una.

Problema. Un cero puede significar que no hubo violencia o que el colegio no tiene cómo registrarla. Si se lee como "aquí no pasa nada", los colegios con menos capacidad quedan fuera de la atención.

Usuarios y beneficiarios. Los usuarios son los especialistas de convivencia de las UGEL y DRE, y el equipo del SíseVe. Los beneficiarios son los estudiantes de primaria.

Objetivo. Agrupar a los colegios según su contexto y sus instrumentos de convivencia, para priorizar dónde un cero es menos confiable.

Pregunta de análisis. ¿Qué características institucionales se asocian a que un colegio registre casos de violencia, y se relaciona ese registro con la repetición y el retiro de sus estudiantes (2024-2025)?

Alcance de este avance. Se trabaja la primera parte de la pregunta. Los datos miden violencia registrada, no ocurrida, así que el clustering no puede separar un colegio sin violencia de uno sin registro: solo ayuda a priorizar. La relación con repetición y retiro queda pendiente para el Hito 4.

II. Datos y representación final

Fuentes. Usamos cuatro fuentes públicas del MINEDU: Censo Educativo 2025 (cédula 3AP), Matrícula 2025, Resultado del Ejercicio Educativo 2025 [2] y Padrón de Instituciones Educativas [3]. Están publicadas en Hugging Face [4]. Para los mapas usamos los límites departamentales del IGN [5].

Unidad de análisis. Cada fila es un colegio de primaria (`COD_MOD` + `ANEXO`). Todos los cruces se validaron como 1 a 1. La matriz analítica tiene 37,354 colegios y 26 columnas.

Representación final. K-means usa 9 atributos (Tabla I), estandarizados con z-score. Quedan 37,260 colegios (99.7 %) con los 9 completos.

Tabla I
Atributos que usa la técnica

Bloque	Atributos
Contexto	Matrícula (logaritmo), área urbana, gestión privada
Convivencia (sí/no)	Responsable de convivencia, afiliado al SíseVe, conoce los protocolos, sabe reportar a la UGEL, consulta el registro de sancionados (RNSSC), actividades de ESI con familias

Exclusiones. El registro de incidencias, las tasas de violencia y el libro de incidencias no entran: incluirlos haría circular el análisis. Tampoco entran la repetición y el retiro. Estas variables solo se usan después para interpretar los grupos. La Tabla II resume las decisiones que más cambiaron el resultado.

III. Metodología

Técnica seleccionada: K-means [6]. La elegimos por tres razones. Primero, responde al objetivo: la UGEL necesita saber qué tipos de colegio existen y no hay una etiqueta de "baja capacidad" con la que entrenar un modelo. Segundo, cada grupo se explica con el promedio de sus atributos. Tercero, procesa todos los colegios, mientras que el jerárquico, en la práctica, requiere una muestra.

Supuestos y limitaciones. K-means busca grupos compactos con distancia euclidiana, y 8 de los 9 atributos son sí/no. Por eso lo comparamos con DBSCAN [7] y con el clustering jerárquico de Ward [8]. También usamos DBSCAN sobre las

Tabla II
PRINCIPALES DECISIONES SOBRE LOS DATOS

Decisión	Por qué
Medir la violencia con el censo y no con las denuncias del SíseVe	Las denuncias solo llegan a nivel UGEL; cruzarlas con colegios era engañoso
Preguntas condicionadas: 0 o vacío según la pregunta filtro	Imputar la mediana asignaba violencia a colegios que declararon cero
Colegios sin libro como grupo propio	5,851 de los 5,875 colegios sin dato no tienen libro: no es falta de respuesta
Logaritmo de la matrícula	Bajó la asimetría de 3.6 a 0.1; no se eliminaron colegios grandes porque son reales
z-score en la técnica	Evita que el tamaño domine; no tener un instrumento pesa más, y eso interesa al problema

coordenadas de los colegios sin libro, como complemento para ubicar zonas de trabajo.

IV. DISEÑO EXPERIMENTAL

Todas las pruebas se ejecutaron con scikit-learn [9] sobre los datos reales. La Tabla III resume qué se probó.

Tabla III
CONFIGURACIONES Y CRITERIOS EVALUADOS

Técnica	Qué se probó	Criterios
K-means	K = 2 a 6; 5 puntos de partida	Inercia, silueta, Davies-Bouldin, ARI
Representación	z-score, 6 componentes de PCA, sin escalar	ARI con la elegida
DBSCAN (atributos)	eps = 2.1 a 3.0; min_samples = 9, 18, 36	Grupos, % de ruido, % en el grupo mayor
Jerárquico	Enlaces ward, complete, average y single; corte en 3 grupos	Tamaños, silueta, Davies-Bouldin, ARI
DBSCAN espacial	eps = 10 a 50 km; min_samples = 30	Zonas, % de ruido

Cómo leer los criterios. La silueta [10] indica si un colegio está más cerca de su grupo que del vecino (más alta es mejor). Davies-Bouldin [11] indica si los grupos son compactos y están separados (más bajo es mejor). El ARI [12] compara dos agrupaciones: 1 significa los mismos grupos y 0, coincidencia por azar.

Valores candidatos. Los valores de eps salieron del gráfico de k-distancias, y min_samples = 18 de la regla de dos veces el número de atributos. La silueta se calculó con una muestra de 10,000 colegios, repetida 5 veces, y el jerárquico se construyó con otra muestra de 10,000, porque con todos habría que comparar casi 700 millones de pares.

V. RESULTADOS PRELIMINARES

V-A. *Número de grupos*

K = 3 y K = 6 no se pueden separar por silueta, porque sus rangos se traslapan (Tabla IV). La diferencia está en la estabilidad: con K = 3 los grupos son idénticos en todas las corridas, y con K = 5 o 6 cambian bastante. K = 2 es estable, pero con peores métricas. Por eso seguimos con K = 3, sin darlo aún por definitivo. La silueta cercana a 0.3 indica una estructura débil: hay colegios intermedios.

Tabla IV
K-MEANS CON DISTINTOS VALORES DE K (D-B = DAVIES-BOULDIN)

K	Inercia	Silueta (rango)	D-B	ARI (rango)
2	261,770	0.261–0.267	1.658	1.00
3	**211,762**	**0.288–0.295**	**1.451**	**1.00**
4	189,734	0.238–0.245	1.480	0.95–1.00
5	171,917	0.254–0.262	1.473	0.40–0.78
6	153,071	0.283–0.292	1.459	0.45–0.98

V-B. *Perfiles de colegios*

La Tabla V y la Fig. 1 muestran los tres grupos. El grupo *Pocos instrumentos* destaca porque el 59 % de sus colegios no tiene libro, aunque el libro no entró al modelo.

Tabla V
PERFIL DE LOS GRUPOS DE K-MEANS

	Urbano grande	Rural con instrumentos	Pocos instrumentos
Colegios	11,460	20,725	5,075
Matrícula promedio	237	35	36
Urbanos	100 %	0 %	16 %
Privados	61 %	0 %	15 %
Con responsable	95 %	95 %	37 %
Conoce protocolos	97 %	95 %	32 %
Sin libro	7 %	12 %	59 %
Con dato de registro	10,656	18,457	2,265
Registran (de esos)	24.5 %	8.8 %	5.5 %

V-C. *Registro a igual tamaño*

Los colegios grandes registran más, así que comparamos los grupos a igual tamaño (Tabla VI). *Pocos instrumentos* registra menos que *Rural con instrumentos* en todos los tamaños. Buena parte del 24.5 % de *Urbano grande* se debe a su tamaño: solo supera al grupo rural con más de 100 estudiantes. Son asociaciones: no sabemos si *Pocos instrumentos* registra menos por tener menos capacidad o porque hay menos violencia.

V-D. *Alternativas comparadas*

Los tres métodos tienen una silueta parecida (Tabla VII). Sus diferencias están en lo que se puede hacer con los grupos.

Jerárquico. Da grupos parecidos a los de K-means: en la muestra, 90.0 % de coincidencia y ARI de 0.76. Al asignar

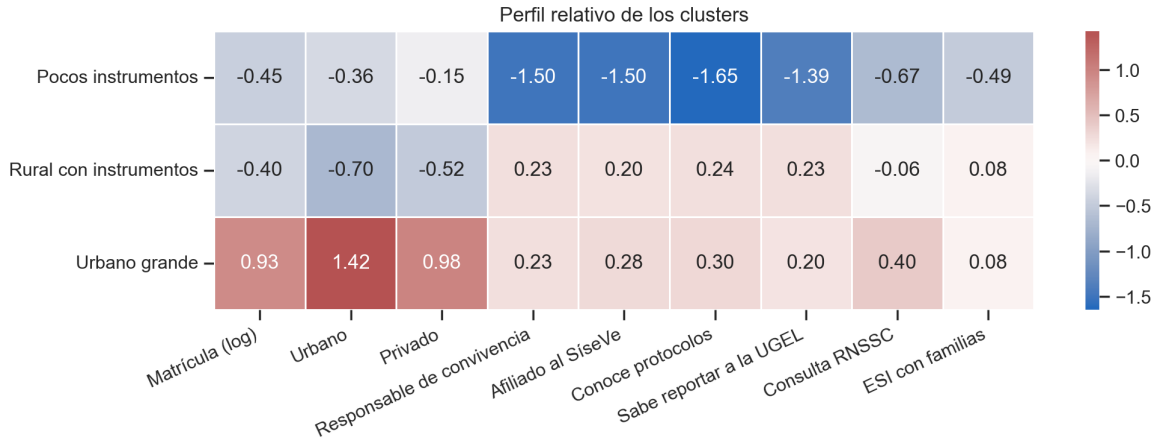


Figura 1. Perfil de cada grupo: cuánto se aleja del promedio nacional en cada atributo (en desviaciones estándar). Rojo = por encima; azul = por debajo.

Tabla VI
COLEGIOS QUE REGISTRAN INCIDENCIAS, SEGÚN TAMAÑO (%)

Estudiantes	≤ 20	21–50	51–100	> 100
Pocos instrumentos	3.1	7.9	7.0	13.0
Rural con instrumentos	4.9	9.0	15.0	22.8
Urbano grande	3.4	7.1	11.4	33.3

al resto por centroides sube a 94.5 % y 0.86, pero ese paso favorece el parecido. Entre los enlaces, *average* tiene la mejor silueta (0.312) y aun así deja un grupo de un solo colegio: una métrica sola puede engañar.

DBSCAN. Depende mucho de eps: pasa de 39 a 2 grupos entre 2.1 y 3.0, mientras que min_samples casi no influye. Como los atributos son sí/no, forma "islas" por combinación de respuestas. Con eps = 2.7, el 75 % de los colegios queda en un grupo y los demás solo indican qué instrumento falta. Aporta un dato para priorizar: 1,112 colegios sin responsable, sin protocolos y sin reporte a la UGEL, de los cuales solo el 15 % tiene libro.

Representación. Con las 6 componentes de PCA los grupos son casi iguales (ARI de 0.995), así que no hace falta usarlas y mantenemos los atributos, que se leen directo. Sin escalar cambian por completo (ARI de 0.26) y se separan sobre todo por tamaño.

Tabla VII
MÉTODOS COMPARADOS SOBRE LOS MISMOS 9 ATRIBUTOS (D-B = DAVIES-BOULDIN)

Método	Grupos	% en el mayor	Silueta	D-B
K-means (K = 3)	3	55.6	0.290	1.451
DBSCAN (eps = 2.7)	8	75.0	0.291	1.476
Jerárquico Ward	3	50.6	0.281	1.553

V-E. Los grupos en el mapa

K-means no usó la ubicación, pero sus grupos forman regiones (Fig. 2). *Pocos instrumentos* pesa más en Loreto (43 %), Ucayali (32 %) y Madre de Dios (29 %). Por su parte, DBSCAN espacial con eps = 30 km encuentra 22 zonas con muchos colegios sin libro; la mayor tiene 1,689 colegios en la sierra norte. En la Amazonía deja como ruido al 56 % de esos colegios, frente al 26 % en el resto del país, porque están dispersos.

VI. PROBLEMAS, LIMITACIONES Y TRABAJO PENDIENTE

Problemas y limitaciones.

- Los datos miden violencia registrada y declarada por el director, no violencia ocurrida.
- Casi todos los colegios sin libro no tienen dato de registro, así que esos porcentajes salen de menos colegios.
- Los atributos sí/no producen muchos colegios idénticos, y el z-score agranda los "no" poco frecuentes.
- La silueta es débil: los grupos sirven para priorizar, no para clasificar.
- Las incidencias son de 2024 y la matrícula de 2025. Es un corte transversal: no permite hablar de causas.

Decisiones abiertas. Si K = 3 da suficiente detalle a la UGEL, y si conviene probar una distancia pensada para atributos sí/no (como Gower) en el jerárquico.

Pendiente antes del Hito 4.

- Reglas de asociación (Apriori) sobre los instrumentos de convivencia.
- Relación de los grupos con la repetición y el retiro.
- Lista priorizada de colegios para la UGEL.
- Pruebas de sensibilidad: umbral de 10 estudiantes en las tasas y colegios con matrícula imputada.
- Comparación final, discusión y conclusiones.

Código y datos. El notebook ejecutado y las instrucciones para reproducirlo están en https://github.com/Mateo-Pereyra/Violencia-dentro-de-los-colegios.

REFERENCIAS

[1] Ministerio de Educación del Perú, "SíseVe: Contra la violencia escolar." [En línea]. Disponible en: https://siseve.minedu.gob.pe

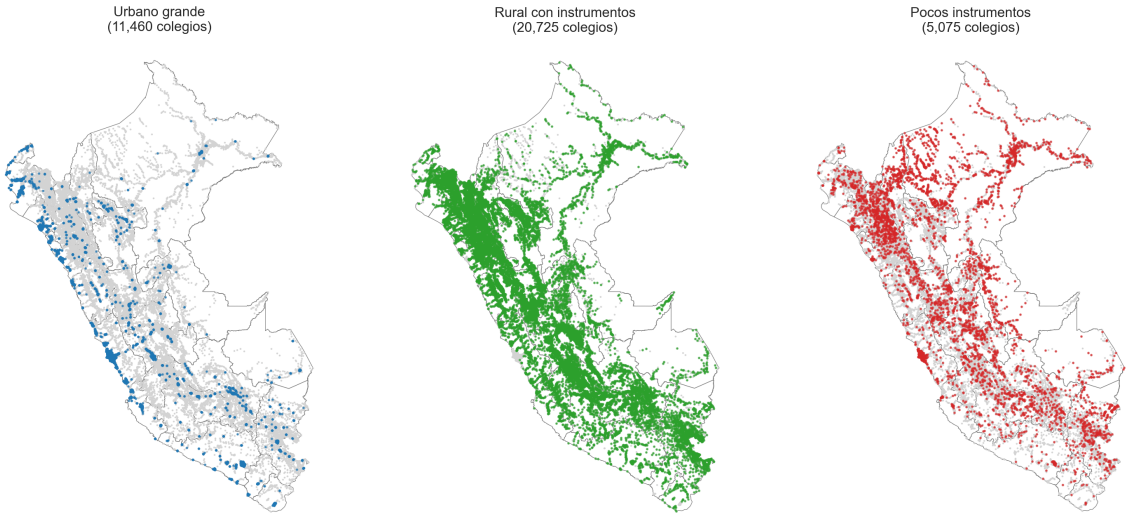


Figura 2. Colegios de cada grupo de K-means en el mapa del Perú. En gris, el resto de colegios.

[2] Ministerio de Educación del Perú, "Censo Educativo y Resultado del Ejercicio Educativo 2025," ESCALE. [En línea]. Disponible en: https://escale.minedu.gob.pe/uee/-/document_library_display/GMv7/view/10632985

[3] Ministerio de Educación del Perú, "Padrón de Instituciones Educativas," ESCALE. [En línea]. Disponible en: https://escale.minedu.gob.pe/web/inicio/padron-de-iiee

[4] Grupo Rompebrechas, "Violencia escolar en primaria: Perú 2024-2025," Hugging Face. [En línea]. Disponible en: https://huggingface.co/datasets/themasterdrop/rompebrechas-violencia-escolar

[5] Instituto Geográfico Nacional del Perú, "Límites administrativos del Perú," 2020.

[6] J. MacQueen, "Some methods for classification and analysis of multivariate observations," en *Proc. 5th Berkeley Symp. Math. Statist. Probab.*, 1967, pp. 281–297.

[7] M. Ester, H.-P. Kriegel, J. Sander y X. Xu, "A density-based algorithm for discovering clusters in large spatial databases with noise," en *Proc. KDD*, 1996, pp. 226–231.

[8] J. H. Ward, "Hierarchical grouping to optimize an objective function," *J. Amer. Statist. Assoc.*, vol. 58, no. 301, pp. 236–244, 1963.

[9] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.

[10] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *J. Comput. Appl. Math.*, vol. 20, pp. 53–65, 1987.

[11] D. L. Davies y D. W. Bouldin, "A cluster separation measure," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. PAMI-1, no. 2, pp. 224–227, 1979.

[12] L. Hubert y P. Arabie, "Comparing partitions," *J. Classification*, vol. 2, pp. 193–218, 1985.