Registro de violencia escolar en colegios de primaria del Perú: perfiles de capacidad institucional con clustering

Mateo Pereyra, Raúl Porras, Mauro Martínez
Curso: Data Mining
Universidad del Pacífico
Docente: Soledad Espezúa Llerena

***Resumen*—La mayoría de colegios de primaria del Perú reporta cero casos de violencia escolar, pero ese cero puede significar que no hubo violencia o que el colegio no puede registrarla. Este avance busca perfiles de colegios según su capacidad institucional, para ayudar a las UGEL a priorizar. Integramos cuatro fuentes públicas del MINEDU y aplicamos K-means sobre nueve atributos de contexto y convivencia en 37,260 colegios. Comparamos K de 2 a 6, tres representaciones y dos métodos alternativos (DBSCAN y jerárquico). K = 3 fue la opción más estable entre las de mejor métrica, aunque la separación entre grupos es débil (silueta 0.29). En el grupo con pocos instrumentos, el 59 % de los colegios no tiene libro de incidencias. Con DBSCAN espacial ubicamos 22 zonas con muchos colegios sin libro y revisamos su sensibilidad a los parámetros. Los resultados son preliminares.**

***Palabras clave*—minería de datos, clustering, K-means, DBSCAN espacial, violencia escolar**

I. Introducción

En el Perú, cada colegio debe anotar los casos de violencia escolar en un libro de incidencias y reportarlos al SíseVe, el portal del Ministerio de Educación (MINEDU) [1]. Con esa información, las Unidades de Gestión Educativa Local (UGEL) deciden a qué colegios acompañar. Pero el 71.5 % de los colegios de primaria tiene libro y anotó cero incidencias en 2024, el 16.8 % no tiene libro y solo el 11.7 % registró al menos una.

Problema. Un cero puede significar que no hubo violencia o que el colegio no tiene cómo registrarla. Si se lee como "aquí no pasa nada", los colegios con menos capacidad quedan fuera de la atención.

Usuarios y beneficiarios. Los usuarios son los especialistas de convivencia de las UGEL y DRE, y el equipo del SíseVe. Los beneficiarios son los estudiantes de primaria.

Objetivo. Agrupar a los colegios según su contexto y sus instrumentos de convivencia, para priorizar dónde un cero es menos confiable.

Pregunta de análisis. ¿Qué características institucionales se asocian a que un colegio registre casos de violencia, y se relaciona ese registro con la repetición y el retiro de sus estudiantes (2024-2025)?

Alcance de este avance. Se trabaja la primera parte de la pregunta. Los datos miden violencia registrada, no ocurrida, así que el clustering no puede separar un colegio sin violencia de uno sin registro: solo ayuda a priorizar. La relación con repetición y retiro queda pendiente para el Hito 4.

II. Datos y representación final

Fuentes. Usamos cuatro fuentes públicas del MINEDU: Censo Educativo 2025 (cédula 3AP), Matrícula 2025, Resultado del Ejercicio Educativo 2025 [2] y Padrón de Instituciones Educativas [3]. Están publicadas en Hugging Face [4]. Para los mapas usamos los límites departamentales del IGN [5].

Unidad de análisis. Cada fila es un colegio de primaria (`COD_MOD` + `ANEXO`). Todos los cruces se validaron como 1 a 1. La matriz analítica tiene 37,354 colegios y 26 columnas.

Representación final. K-means usa 9 atributos (Tabla I), estandarizados con z-score. Quedan 37,260 colegios (99.7 %) con los 9 completos. El clustering espacial usa otra representación: solo las coordenadas, en metros (UTM 18S), de los 6,269 colegios sin libro de incidencias.

Tabla I
Atributos que usa la técnica

Bloque	Atributos
Contexto	Matrícula (logaritmo), área urbana, gestión privada
Convivencia (sí/no)	Responsable de convivencia, afiliado al SíseVe, conoce los protocolos, sabe reportar a la UGEL, consulta el registro de sancionados (RNSSC), actividades de ESI con familias

Exclusiones. El registro de incidencias, las tasas de violencia y el libro de incidencias no entran: incluirlos haría circular el análisis. Tampoco entran la repetición y el retiro. Estas variables solo se usan después para interpretar los grupos. La Tabla II resume las decisiones que más cambiaron el resultado.

III. Metodología

Técnica seleccionada: K-means [6]. La elegimos por tres razones. Primero, responde al objetivo: la UGEL necesita saber qué tipos de colegio existen y no hay una etiqueta de "baja capacidad" con la que entrenar un modelo. Segundo, cada grupo se explica con el promedio de sus atributos. Tercero, procesa todos los colegios, mientras que el jerárquico, en la práctica, requiere una muestra.

Tabla II
PRINCIPALES DECISIONES SOBRE LOS DATOS

Decisión	Por qué
Medir la violencia con el censo y no con las denuncias del SíseVe	Las denuncias solo llegan a nivel UGEL; cruzarlas con colegios era engañoso
Preguntas condicionadas: 0 o vacío según la pregunta filtro	Imputar la mediana asignaba violencia a colegios que declararon cero
Colegios sin libro como grupo propio	5,851 de los 5,875 colegios sin dato no tienen libro: no es falta de respuesta
Logaritmo de la matrícula	Bajó la asimetría de 3.6 a 0.1; no se eliminaron colegios grandes porque son reales
z-score en la técnica	Evita que el tamaño domine; no tener un instrumento pesa más, y eso interesa al problema
Coordenadas en metros para DBSCAN espacial	En grados, eps no es una distancia: con eps = 30,000 todo el país queda en una zona

Supuestos y limitaciones. K-means busca grupos compactos con distancia euclidiana, y 8 de los 9 atributos son sí/no. Por eso lo comparamos con DBSCAN [7] y con el clustering jerárquico de Ward [8].

Componente espacial. Usamos tres enfoques con preguntas distintas. El principal es el clustering por atributos visto después en el mapa: responde qué colegios tienen poca capacidad de registro y muestra dónde están. Como apoyo, DBSCAN sobre las coordenadas de los colegios sin libro ubica zonas donde una sola capacitación llega a muchos colegios. El mapa de calor solo sirve para comunicar, porque no forma grupos. Los resultados se entregan también en un mapa interactivo (Folium) que la UGEL puede abrir sin Python.

IV. DISEÑO EXPERIMENTAL

Todas las pruebas se ejecutaron con scikit-learn [9] sobre los datos reales. La Tabla III resume qué se probó.

Cómo leer los criterios. La silueta [10] indica si un colegio está más cerca de su grupo que del vecino (más alta es mejor). Davies-Bouldin [11] indica si los grupos son compactos y están separados (más bajo es mejor). El ARI [12] compara dos agrupaciones: 1 significa los mismos grupos y 0, coincidencia por azar. En el clustering espacial no usamos la silueta, porque ignora el ruido; medimos cuánto ruido queda y la distancia mediana de cada colegio al centro de su grupo, que indica si una sola visita puede llegar a todos.

Valores candidatos. Los valores de eps salieron del gráfico de k-distancias, y min_samples = 18 de la regla de dos veces el número de atributos. La silueta se calculó con una muestra de 10,000 colegios, repetida 5 veces, y el jerárquico se construyó con otra muestra de 10,000, porque con todos habría que comparar casi 700 millones de pares. En DBSCAN espacial, min_samples = 30 porque interesan zonas con muchos colegios; el gráfico de 30-distancias se dispara después de 60–75 km, el máximo razonable, y elegimos eps = 30 km, una escala parecida a la de una provincia. Para el desafío del laboratorio probamos la mitad y el doble de min_samples (15 y 60) y, en K-means y jerárquico con coordenadas, 22 grupos (los de DBSCAN) y 4.

Tabla III
CONFIGURACIONES Y CRITERIOS EVALUADOS

Técnica	Qué se probó	Criterios
K-means	K = 2 a 6; 5 puntos de partida	Inercia, silueta, Davies-Bouldin, ARI
K-means en el mapa	K = 2 y K = 4 frente a K = 3	Qué grupos se juntan o se parten; si forman regiones
Representación	z-score, 6 componentes de PCA, sin escalar	ARI con la elegida
DBSCAN (atributos)	eps = 2.1 a 3.0; min_samples = 9, 18, 36	Grupos, % de ruido, % en el grupo mayor
Jerárquico	Enlaces ward, complete, average y single; corte en 3 grupos	Tamaños, silueta, Davies-Bouldin, ARI
DBSCAN espacial	eps = 10 a 50 km con min_samples = 30; min_samples = 15, 30 y 60 con eps = 30 km	Zonas, % de ruido (total y en la Amazonía), zona mayor
K-means y jerárquico con coordenadas	22 y 4 grupos	Ruido, distancia al centro del grupo

V. RESULTADOS PRELIMINARES

V-A. Número de grupos

K = 3 y K = 6 no se pueden separar por silueta, porque sus rangos se traslapan (Tabla IV). La diferencia está en la estabilidad: con K = 3 los grupos son idénticos en todas las corridas, y con K = 5 o 6 cambian bastante. K = 2 es estable, pero con peores métricas. Por eso seguimos con K = 3, sin darlo aún por definitivo. La silueta cercana a 0.3 indica una estructura débil: hay colegios intermedios.

Tabla IV
K-MEANS CON DISTINTOS VALORES DE K (D-B = DAVIES-BOULDIN)

K	Inercia	Silueta (rango)	D-B	ARI (rango)
2	261,770	0.261–0.267	1.658	1.00
3	**211,762**	**0.288–0.295**	**1.451**	**1.00**
4	189,734	0.238–0.245	1.480	0.95–1.00
5	171,917	0.254–0.262	1.473	0.40–0.78
6	153,071	0.283–0.292	1.459	0.45–0.98

V-B. Perfiles de colegios

La Tabla V y la Fig. 1 muestran los tres grupos. El grupo *Pocos instrumentos* destaca porque el 59 % de sus colegios no tiene libro, aunque el libro no entró al modelo.

Tabla V
PERFIL DE LOS GRUPOS DE K-MEANS

	Urbano grande	Rural con instrumentos	Pocos instrumentos
Colegios	11,460	20,725	5,075
Matrícula promedio	237	35	36
Urbanos	100 %	0 %	16 %
Privados	61 %	0 %	15 %
Con responsable	95 %	95 %	37 %
Conoce protocolos	97 %	95 %	32 %
Sin libro	7 %	12 %	59 %
Con dato de registro	10,656	18,457	2,265
Registran (de esos)	24.5 %	8.8 %	5.5 %

V-C. Registro a igual tamaño

Los colegios grandes registran más, así que comparamos los grupos a igual tamaño (Tabla VI). *Pocos instrumentos* registra menos que *Rural con instrumentos* en todos los tamaños. Buena parte del 24.5 % de *Urbano grande* se debe a su tamaño: solo supera al grupo rural con más de 100 estudiantes. Son asociaciones: no sabemos si *Pocos instrumentos* registra menos por tener menos capacidad o porque hay menos violencia.

Tabla VI
COLEGIOS QUE REGISTRAN INCIDENCIAS, SEGÚN TAMAÑO (%)

Estudiantes	≤ 20	21–50	51–100	> 100
Pocos instrumentos	3.1	7.9	7.0	13.0
Rural con instrumentos	4.9	9.0	15.0	22.8
Urbano grande	3.4	7.1	11.4	33.3

V-D. Alternativas comparadas

Los tres métodos tienen una silueta parecida (Tabla VII). Sus diferencias están en lo que se puede hacer con los grupos.

Jerárquico. Da grupos parecidos a los de K-means: en la muestra, 90.0 % de coincidencia y ARI de 0.76. Al asignar al resto por centroides sube a 94.5 % y 0.86, pero ese paso favorece el parecido. Entre los enlaces, *average* tiene la mejor silueta (0.312) y aun así deja un grupo de un solo colegio: una métrica sola puede engañar.

DBSCAN. Depende mucho de eps: pasa de 39 a 2 grupos entre 2.1 y 3.0, mientras que min_samples casi no influye. Como los atributos son sí/no, forma "islas" por combinación de respuestas. Con eps = 2.7, el 75 % de los colegios queda en un grupo y los demás solo indican qué instrumento falta. Aporta un dato para priorizar: 1,112 colegios sin responsable, sin protocolos y sin reporte a la UGEL, de los cuales solo el 15 % tiene libro.

Representación. Con las 6 componentes de PCA los grupos son casi iguales (ARI de 0.995), así que no hace falta usarlas y mantenemos los atributos, que se leen directo. Sin escalar cambian por completo (ARI de 0.26) y se separan sobre todo por tamaño.

Tabla VII
MÉTODOS COMPARADOS SOBRE LOS MISMOS 9 ATRIBUTOS (D-B = DAVIES-BOULDIN)

Método	Grupos	% en el mayor	Silueta	D-B
K-means (K = 3)	3	55.6	0.290	1.451
DBSCAN (eps = 2.7)	8	75.0	0.291	1.476
Jerárquico Ward	3	50.6	0.281	1.553

V-E. Los grupos en el mapa

K-means no usó la ubicación, pero sus grupos forman regiones (Fig. 2). *Pocos instrumentos* pesa más en Loreto (43 %), Ucayali (32 %) y Madre de Dios (29 %).

¿Dependen de elegir K = 3? Con K = 2, *Pocos instrumentos* desaparece: el 85 % de sus colegios pasa al grupo rural y el mapa queda dividido solo entre ciudades y campo. Con K = 4 ese grupo se mantiene (98 % de sus colegios) y lo que se parte es el grupo rural, según si hace actividades de ESI con familias. El grupo que más interesa a la UGEL no depende de elegir exactamente K = 3, pero se pierde si se usan menos grupos.

V-F. Clustering espacial de los colegios sin libro

DBSCAN con eps = 30 km y min_samples = 30 encuentra 22 zonas con muchos colegios sin libro; la mayor tiene 1,689 colegios en la sierra norte. En la Amazonía deja como ruido al 56 % de esos colegios, frente al 26 % en el resto del país, porque están dispersos a lo largo de los ríos.

La Tabla VIII y la Fig. 3 muestran cuánto depende eso de los parámetros. Con min_samples = 15, el ruido amazónico baja al 18 %, pero las zonas de la sierra norte se encadenan en una de 3,236 colegios y la mitad de los colegios queda a más de 150 km del centro de su zona; con 60 quedan 10 zonas y el 84 % de los colegios amazónicos es ruido. K-means y el jerárquico sobre las mismas coordenadas no dejan ruido, pero sus grupos son más extensos, y con 4 grupos son regiones enteras. Como en el laboratorio, para encontrar concentraciones conviene DBSCAN; los colegios amazónicos aislados se leen mejor con el mapa de proporciones por departamento y provincia.

Tabla VIII
CLUSTERING ESPACIAL DE LOS 6,269 COLEGIOS SIN LIBRO (DIST. = MEDIANA DE LA DISTANCIA AL CENTRO DEL GRUPO)

Configuración	Grupos	% ruido	% ruido Amazonía	Dist. (km)
DBSCAN, min_samples = 15	26	11	18	154
DBSCAN, min_samples = 30	**22**	**34**	**56**	**45**
DBSCAN, min_samples = 60	10	65	84	26
K-means, 22 grupos	22	0	0	68
Jerárquico, 22 grupos	22	0	0	69
K-means, 4 grupos	4	0	0	174
Jerárquico, 4 grupos	4	0	0	173

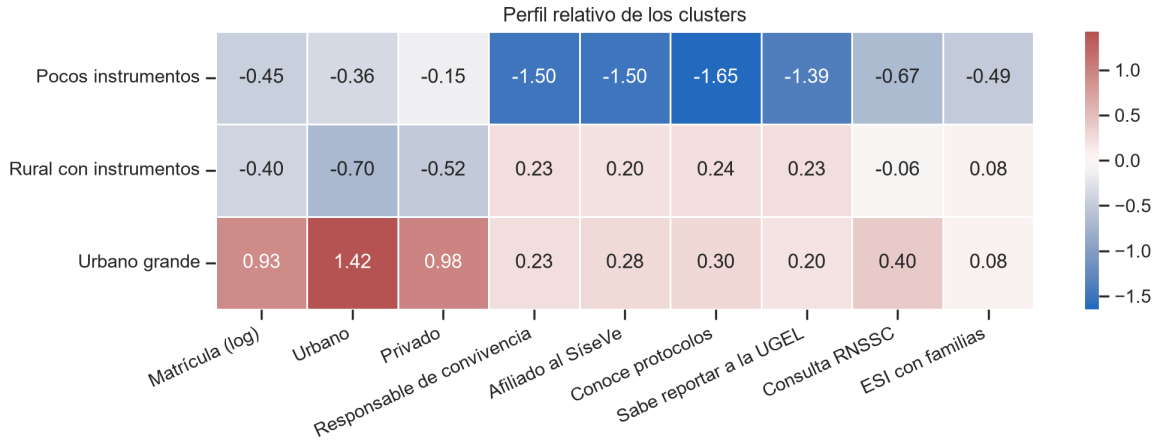


Figura 1. Perfil de cada grupo: cuánto se aleja del promedio nacional en cada atributo (en desviaciones estándar). Rojo = por encima; azul = por debajo.

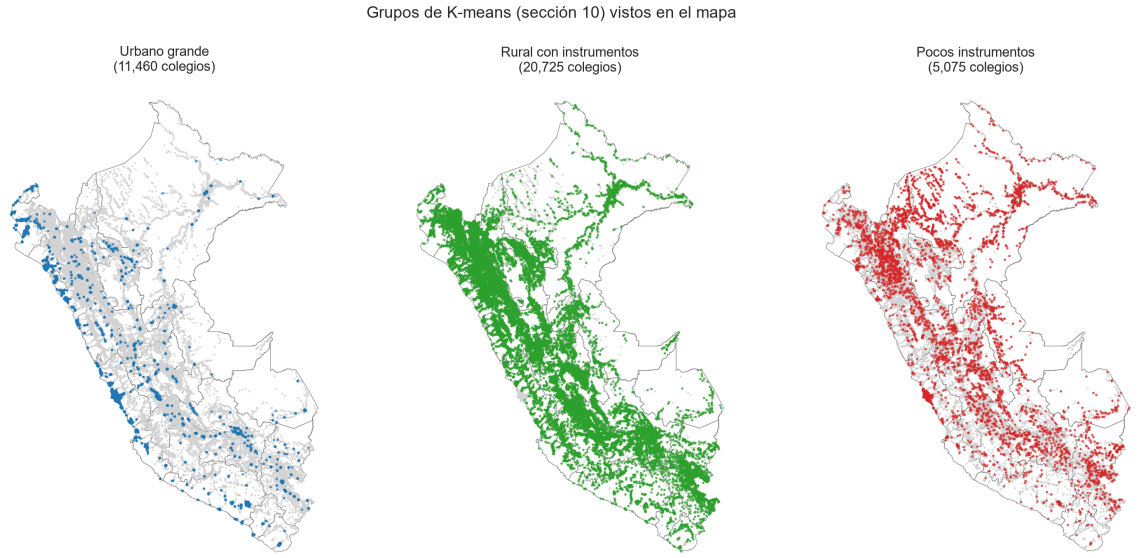


Figura 2. Colegios de cada grupo de K-means en el mapa del Perú. En gris, el resto de colegios.

VI. Problemas, limitaciones y trabajo pendiente

Problemas y limitaciones.

- Los datos miden violencia registrada y declarada por el director, no violencia ocurrida.
- Casi todos los colegios sin libro no tienen dato de registro, así que esos porcentajes salen de menos colegios.
- Los atributos sí/no producen muchos colegios idénticos, y el z-score agranda los "no" poco frecuentes.
- La silueta es débil: los grupos sirven para priorizar, no para clasificar.
- DBSCAN espacial deja como ruido a muchos colegios amazónicos; bajar min_samples lo reduce, pero une zonas lejanas.
- Las incidencias son de 2024 y la matrícula de 2025. Es un corte transversal: no permite hablar de causas.

Decisiones abiertas. Si K = 3 da suficiente detalle a la UGEL (K = 4 separa a los colegios rurales según las actividades de ESI), y si conviene probar una distancia pensada para atributos sí/no (como Gower) en el jerárquico.

Pendiente antes del Hito 4.

- Reglas de asociación (Apriori) sobre los instrumentos de convivencia.
- Relación de los grupos con la repetición y el retiro.
- Lista priorizada de colegios para la UGEL; el mapa interactivo ya los ubica.
- Pruebas de sensibilidad: umbral de 10 estudiantes en las tasas y colegios con matrícula imputada.
- Comparación final, discusión y conclusiones.

Código y datos. El notebook ejecutado, el mapa interactivo y las instrucciones para reproducirlo están en https://github.com/Mateo-Pereyra/Violencia-dentro-de-los-colegios.

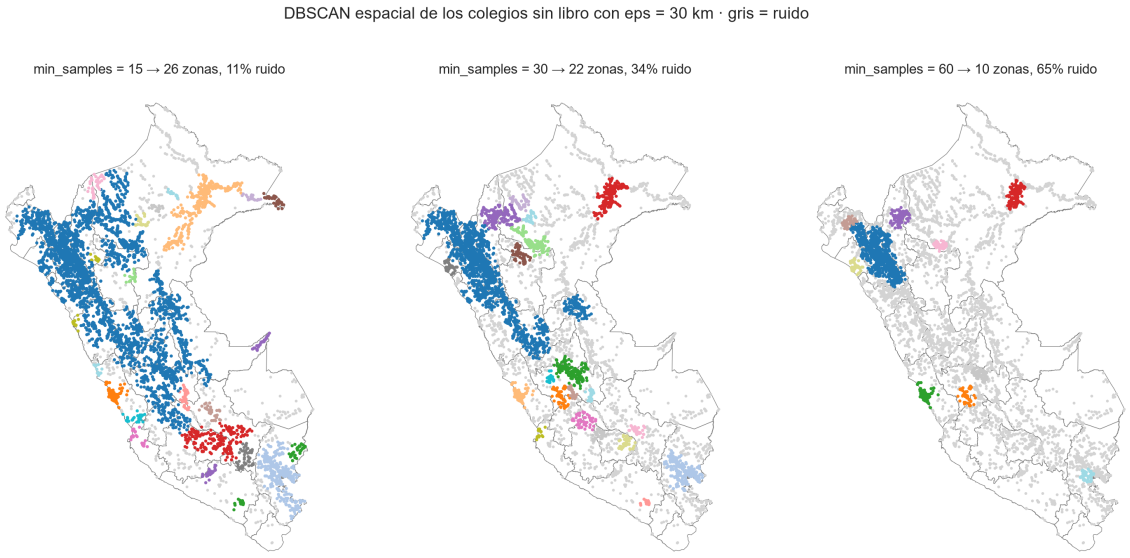


Figura 3. DBSCAN espacial de los colegios sin libro con eps = 30 km y tres valores de min_samples. Cada color es una zona; en gris, los colegios que quedan como ruido.

REFERENCIAS

[1] Ministerio de Educación del Perú, "SíseVe: Contra la violencia escolar." [En línea]. Disponible en: https://siseve.minedu.gob.pe

[2] Ministerio de Educación del Perú, "Censo Educativo y Resultado del Ejercicio Educativo 2025," ESCALE. [En línea]. Disponible en: https://escale.minedu.gob.pe/uee/-/document_library_display/GMv7/view/10632985

[3] Ministerio de Educación del Perú, "Padrón de Instituciones Educativas," ESCALE. [En línea]. Disponible en: https://escale.minedu.gob.pe/web/inicio/padron-de-iiee

[4] Grupo Rompebrechas, "Violencia escolar en primaria: Perú 2024-2025," Hugging Face. [En línea]. Disponible en: https://huggingface.co/datasets/themasterdrop/rompebrechas-violencia-escolar

[5] Instituto Geográfico Nacional del Perú, "Límites administrativos del Perú," 2020.

[6] J. MacQueen, "Some methods for classification and analysis of multivariate observations," en *Proc. 5th Berkeley Symp. Math. Statist. Probab.*, 1967, pp. 281–297.

[7] M. Ester, H.-P. Kriegel, J. Sander y X. Xu, "A density-based algorithm for discovering clusters in large spatial databases with noise," en *Proc. KDD*, 1996, pp. 226–231.

[8] J. H. Ward, "Hierarchical grouping to optimize an objective function," *J. Amer. Statist. Assoc.*, vol. 58, no. 301, pp. 236–244, 1963.

[9] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.

[10] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *J. Comput. Appl. Math.*, vol. 20, pp. 53–65, 1987.

[11] D. L. Davies y D. W. Bouldin, "A cluster separation measure," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. PAMI-1, no. 2, pp. 224–227, 1979.

[12] L. Hubert y P. Arabie, "Comparing partitions," *J. Classification*, vol. 2, pp. 193–218, 1985.